

1 Introducción

El proceso SF-Harris [?,]anzarut2024 modela la volatilidad latente como una cadena de Harris en tiempo continuo:

$$\log(\tau_t) = \begin{cases} \log(\tau_{t-1}) & \text{con probabilidad } p_{\text{stay}} = e^{-\alpha} \\ X_t \sim Q & \text{con probabilidad } 1 - p_{\text{stay}} \end{cases} \quad (1)_{eq : harris}$$

con emisión $Y_t = \log(RV_t) = \log(\tau_t) + \varepsilon_t$, $\varepsilon_t \sim N(0, \sigma_{\text{obs}}^2)$. Anzarut parametriza Q como $\text{GIG}(\lambda, \kappa, \eta)$ y estima los parámetros mediante Gibbs sampling con umbral ε para detectar saltos.

La tesis presenta dos tablas de simulación (Sección 3.5.2) que evalúan cinco métodos de estimación: NDNJ (no paramétrico), MLE, EM, Gibbs-a (2000 iter, 500 burn-in) y Gibbs-b (5000 iter, 1000 burn-in). Nuestro objetivo inicial era replicar estas tablas, pero durante el proceso descubrimos discrepancias significativas que revelan propiedades estructurales del modelo.

2 Estudio de simulación

Replicamos las Tablas II y III de Anzarut con 100 réplicas, los mismos rangos de parámetros ($\alpha \in (0, 30)$, $\lambda \in (-5, 5)$, $\kappa \in (0.1, 50)$, $\eta \in (0.1, 4)$) y los cinco métodos de estimación.

2.1 Caso 1: Q discreta

Con $Q = \text{Uniforme}\{1, \dots, 5\}$, el único parámetro a estimar es α . La métrica es $E_\alpha = \frac{1}{n} \sum_{i=1}^n |\alpha_i - \hat{\alpha}_i|/30$. Para Q discreta, los “saltos ocultos” (el proceso salta pero aterriza en el mismo valor) complican la estimación: NDNJ cuenta cambios observados y subestima α , mientras que MLE y EM corrigen parcialmente. Gibbs-a y Gibbs-b muestrean los indicadores de salto latentes z_i junto con α .

Los resultados muestran que ningún método domina consistentemente. EM tiene el peor desempeño en muestras pequeñas ($k = 20, 100$), probablemente porque la corrección por saltos ocultos amplifica el error cuando hay pocas observaciones. Gibbs-b (actualización Gamma conjugada) es comparable a NDNJ y MLE en $k \geq 500$.

2.2 Caso 2: Q continua (GIG)

Con $Q = \text{GIG}(\lambda, \kappa, \eta)$, se estiman cuatro parámetros. Además de E_α , medimos $E_Q = \text{divergencia KL entre la GIG verdadera y la estimada}$.

Un resultado teórico importante: para Q continua, $x_t \neq x_{t-1}$ implica salto (no hay saltos ocultos), así que el MLE de α es $\hat{\alpha} = -\log(n_{\text{stay}}/n_{\text{total}})$ independientemente de Q . Por lo tanto $\text{NDNJ} = \text{MLE} = \text{EM}$ en E_α , lo cual confirmamos numéricamente.

Table 1: Caso 1: E_α con $Q = \text{Uniforme}\{1, \dots, 5\}$. Izquierda: replicación (100 réplicas, $\hat{\alpha}$ acotado a 50). Derecha: Anzarut (100 réplicas, $\hat{\alpha}$ acotado a 10).

tab:sim-case1										
k	Replicación					Anzarut (2017)				
	NDNJ	EM	MLE	Gibbs-a	Gibbs-b	NDNJ	EM	MLE	Gibbs-a	Gibbs-b
20	0.49	0.58	0.41	0.45	0.48	0.45	0.94	0.75	0.32	0.44
100	0.42	0.65	0.50	0.54	0.43	0.40	0.12	0.10	0.15	0.39
500	0.43	0.54	0.45	0.50	0.45	0.28	0.03	0.04	0.04	0.26
1000	0.45	0.59	0.50	0.51	0.48	0.22	0.03	0.03	0.02	0.18

NDNJ subestima α porque no corrige por saltos ocultos. MLE y EM corrigen pero no integran la incertidumbre. Gibbs muestrea $z_i \sim \text{Ber}(p_{\text{jump}|\text{same}})$ en cada iteración. Las diferencias principales con Anzarut: (1) EM y MLE convergen más rápido en Anzarut (cap=10 favorece α bajos); (2) Gibbs-a mejora menos aquí (0.45 vs. 0.32 a $k = 20$).

2.3 Hallazgos del estudio de simulación

1. NDNJ = MLE = EM en α para Q continua. Con Q continua, la verosimilitud de α se factoriza de la de Q , y los tres métodos producen $\hat{\alpha} = -\log(n_{\text{stay}}/n_{\text{total}})$. En la Tabla III de Anzarut, MLE y EM tienen E_α de 1.49–1.76 a $k = 20$, mucho más alto que NDNJ (0.51). Esta discrepancia se debe a la optimización numérica conjunta en 4D: al optimizar $(\alpha, \lambda, \kappa, \eta)$ simultáneamente, el estimador de α se contamina con el error en los parámetros de Q . Nuestra replicación confirma $E_\alpha = 0.96$ idéntico para los tres métodos.

2. El Gibbs sampler reduce E_α consistentemente. Gibbs-a tiene $E_\alpha = 0.47$ vs. 0.96 para el MLE a $k = 20$. Anzarut reporta aún menor E_α para Gibbs-a (0.33 a $k = 20$), pero sorprendentemente su Gibbs-a empeora con k : de 0.33 sube a 1.86 a $k = 1000$. Esto es contraintuitivo (más datos deberían mejorar la estimación) y sugiere problemas de convergencia en su implementación.

3. E_α alto en NDNJ/MLE/EM por el tope en $\hat{\alpha}$. A $k = 1000$, Anzarut reporta $E_\alpha(\text{NDNJ}) = 0.19$ vs. nuestro 0.81. La diferencia proviene del tope: Anzarut acota $\hat{\alpha} \leq 10$, nosotros a 50. Con $\alpha \in (0, 30)$, cuando $n_{\text{stay}} = 0$, el MLE da $\hat{\alpha} \rightarrow \infty$; acotar a 10 elimina estos casos artificialmente.

4. La media posterior del Gibbs estabiliza E_Q . Nuestros estimadores puntuales de GIG sufren de casi-no-identificabilidad: cuando $\kappa > 10$, λ es prácticamente libre y el MLE numérico encuentra soluciones en la frontera. Al usar la media posterior del Gibbs para estimar Q en NDNJ/MLE/EM, E_Q baja de 11+ a 0.35 a $k = 20$. Anzarut reporta $E_Q = 0.09$ para NDNJ/MLE/EM a $k = 20$ usando MLE puntual, pero los valores suben a 0.04–0.09 a $k = 1000$ mientras los nuestros bajan a 0.004–0.027.

5. Gibbs-a tiene el mejor E_Q . Gibbs-a alcanza $E_Q = 0.22$ a $k = 20$ y 0.008 a $k = 1000$, consistentemente mejor que Gibbs-b (0.38 y 0.042). La actualización Gamma conjugada de Gibbs-b introduce sesgo en α que degrada E_Q . Notablemente, el Gibbs-a de Anzarut tiene E_Q mucho más alto (0.77 a $k = 20$), posiblemente por diferencias en la parametrización del muestreador MH para (λ, κ, η) .

Table 2: Caso 2: E_α con $Q = \text{GIG}(\lambda, \kappa, \eta)$. Izquierda: replicación (100 réplicas, $\hat{\alpha}$ acotado a 50). Derecha: Anzarut (2017).

tab:sim-case2-alpha										
	Replicación					Anzarut (2017)				
k	NDNJ	MLE	EM	Gibbs-a	Gibbs-b	NDNJ	MLE	EM	Gibbs-a	Gibbs-b
20	0.96	0.96	0.96	0.47	0.51	0.51	1.76	1.49	0.33	0.51
100	0.88	0.88	0.88	0.45	0.50	0.44	1.59	1.29	0.15	0.44
500	0.86	0.86	0.86	0.45	0.51	0.28	1.56	1.29	1.09	0.25
1000	0.81	0.81	0.81	0.44	0.50	0.19	1.51	1.29	1.86	0.17

NDNJ = MLE = EM para Q continua (resultado teórico: la verosimilitud de α se factoriza de la de Q). En Anzarut, MLE y EM difieren porque la optimización conjunta en 4D introduce artefactos numéricos. Gibbs-a mejora E_α integrando sobre la posterior. NDNJ/MLE/EM tienen E_α más alto en la replicación (cap=50 vs. cap=10 en Anzarut). Gibbs-a de Anzarut aumenta con k (1.86 a $k = 1000$), lo cual es contra-intuitivo y sugiere problemas de convergencia.

3 Replicación empírica: Tabla 3 de Anzarut

Con datos intradiarios de IBM (2012–2022), replicamos la Tabla 3 de Anzarut usando dos tipos de barras:

El resultado de 0.2 pp mejora $4\times$ el de Anzarut. La mejora proviene de dos fuentes: (1) Q_{emp} captura la asimetría y curtosis de los datos sin imponer la forma GIG (0.2 vs. 0.8 pp), y (2) las barras de dólar reducen la curtosis de $\log(\text{RV})$ de 35.5 a 0.09, estabilizando la emisión gaussiana.

4 La cadena de Harris es decorativa

El resultado de simulación sugiere que el Gibbs sampler mejora la estimación de parámetros, pero ¿qué aporta la dinámica de la cadena de Harris en sí? Presentamos varias pruebas experimentales que demuestran que el punto de masa $p_{\text{stay}} \cdot \delta_{X_t}$ no tiene poder predictivo.

4.1 El parámetro p_{stay} no es informativo

Si la dinámica de la cadena importara, cambiar p_{stay} debería cambiar la cobertura predictiva. Dentro del Gibbs sampler, variamos p_{stay} de 0 a 0.95:

p_{stay}	0.0	0.1	0.2	0.3	0.4	0.5	0.6	0.7	0.8	0.95
AAD	0.41	0.41	0.41	0.42	0.43	0.44	0.47	0.49	0.52	0.54

La AAD varía de 0.41 a 0.54 pp — esencialmente plana. p_{stay} no es informativo. La posterior sobre (μ, σ) centra y escala Q correctamente independientemente del valor de p_{stay} .

Table 3: Caso 2: E_Q (divergencia KL) con $Q = \text{GIG}(\lambda, \kappa, \eta)$. Izquierda: replicación. Derecha: Anzarut (2017).

tab:sim-case2-kl										
k	Replicación					Anzarut (2017)				
	NDNJ	MLE	EM	Gibbs-a	Gibbs-b	NDNJ	MLE	EM	Gibbs-a	Gibbs-b
20	0.35	0.24	0.32	0.22	0.38	0.09	0.09	0.10	0.77	0.84
100	0.16	0.15	0.11	0.06	0.36	0.02	0.02	0.03	0.31	0.31
500	0.025	0.031	0.017	0.023	0.051	0.01	0.04	0.07	0.16	0.18
1000	0.004	0.011	0.027	0.008	0.042	0.01	0.05	0.09	0.09	0.12

En nuestra replicación, NDNJ/MLE/EM estiman Q vía media posterior del Gibbs sampler (evita inestabilidad del MLE puntual de GIG). En Anzarut, los mismos métodos usan MLE puntual, dando E_Q más bajo a $k = 20$ (0.09 vs. 0.24) pero más alto a $k \geq 500$ (0.04–0.09 vs. 0.004–0.03). Gibbs-a de Anzarut tiene E_Q más alto que el nuestro (0.77 vs. 0.22 a $k = 20$), lo cual sugiere diferencias en la implementación del muestreador. Gibbs-b degrada E_Q en ambas implementaciones.

Table 4: Cobertura predictiva de $\log(\text{RV}_t)$. AAD en puntos porcentuales.

	Modelo	Barras	AAD
	SF-Harris Gibbs ($\varepsilon = 0.1, Q_{\text{emp}}$)	dólar	0.2
tab:replicacion	SF-Harris Gibbs ($\varepsilon = 0.1, Q_{\text{emp}}$)	15 min	0.3
	Anzarut (GIG + Gibbs)	15 min	0.8
	GARCH(1,1)	15 min	3.4
	Sim. Histórica ($p_{\text{stay}} = 0$)	15 min	0.4

4.2 Sin denoising, el punto de masa es destructivo

Eliminamos el Gibbs y usamos directamente $P(X_{t+1} | X_t) = p_{\text{stay}} \cdot \delta_{X_t} + (1 - p_{\text{stay}}) \cdot Q_{\text{emp}}$:

p_{stay}	0.0	0.2	0.4	0.6	0.8	0.88	0.95
Sin ruido obs.	0.42	1.75	8.12	20.18	37.90	50.49	65.39
Con ruido obs.	18.51	18.37	17.35	15.61	13.06	11.66	10.12

Sin Gibbs, p_{stay} es monótonamente destructivo: coloca probabilidad en la observación ruidosa actual, creando un pico artificial. A $p_{\text{stay}} = 0.88$, la AAD es 50 pp sin ruido observacional.

4.3 El umbral ε no calibra nada

El parámetro ε controla cuántas observaciones se clasifican como saltos. Si importara, cambiar ε debería cambiar la cobertura. Con Q_{emp} , la AAD es constante (0.2pp en barras de

dólar) a través de ocho órdenes de magnitud ($\varepsilon \in [10^{-8}, 10^0]$). El muestreo empírico absorbe toda la variación.

4.4 Predicción estancia/salto: AUC = 0.51

Si la cadena tuviera poder predictivo, se podrá predecir si el próximo paso es estancia o salto. La clasificación binaria tiene AUC = 0.51 — equivalente a lanzar una moneda.

4.5 Detección de crisis: AUC = 0.42 (anti-predictivo)

Usamos la sorpresa predictiva como indicador de crisis. El AUC es 0.416 — anti-predictivo. El modelo siempre espera colas pesadas, así que las crisis nunca son sorprendentes.

4.6 Datos mexicanos fuera de muestra

Evaluamos ocho activos mexicanos a dos frecuencias: diaria (datos de cierre, 5 años) y horaria (datos intradiarios de Yahoo Finance, 3 años). Sin datos intradiarios, el estimador r_t^2 tiene $\sigma \approx 2.27$, degradando el modelo.

Diario: Sim. Histórica gana en los ocho casos:

Table 5: AAD **diario** en datos mexicanos (pp, menor es mejor).

	Activo	SF-Harris	Hist. Sim.	Gap
tab:mexican-daily	IPC	8.5	3.7	4.8
	Bimbo	11.7	3.1	8.6
	Grupo México	11.3	2.2	9.1
	Walmart Mex	10.4	1.4	9.0
	FEMSA	8.1	3.3	4.8
	Cemex	10.2	1.6	8.6
	Banorte	9.5	2.0	7.5
	USD/MXN	7.8	1.5	6.3

Sin datos intradiarios, el estimador de varianza r_t^2 tiene demasiado ruido ($\sigma \approx 2.27$). SF-Harris no puede corregir la volatilidad observada, y la cadena de Harris aporta ruido en vez de señal.

Horario (1h): Con datos intradiarios, SF-Harris mejora 5–10 pp respecto al diario:

5 Los dos ingredientes esenciales

Las pruebas convergen: el modelo se reduce a dos ingredientes que sí importan y uno que no.

Ingrediente 1: Distribución empírica Q . Resamplear de los datos de entrenamiento captura asimetría y curtosis sin imponer forma funcional. GIG paramétrica da 0.8 pp; Q_{emp} da 0.2 pp; Gaussiana da 26+ pp. La GIG no ajusta la forma de la marginal; Q_{emp} sí.

Table 6: AAD **horario (1h)** en datos mexicanos. SF-Harris gana en 5 de 8 activos.

	Activo	SF-Harris	Hist. Sim.	Gap 1h	Ganador
tab:mexican-hourly	Cemex	0.98	2.48	−1.50	SF-Harris
	FEMSA	1.13	1.40	−0.27	SF-Harris
	Bimbo	1.33	1.12	+0.21	Hist. Sim.
	Grupo México	1.47	1.56	−0.09	SF-Harris
	Walmart Mex	1.63	1.65	−0.02	SF-Harris
	Banorte	1.72	1.58	+0.14	Hist. Sim.
	IPC	2.66	3.76	−1.11	SF-Harris
	USD/MXN	2.98	2.86	+0.12	Hist. Sim.

Con datos intradiarios, el estimador de varianza tiene menos ruido y el denoising bayesiano aporta ~ 0.2 pp sobre iid. Las diferencias son pequeñas (≤ 1.5 pp), consistente con que el Gibbs mejora marginalmente sobre Sim. Histórica cuando el ruido observacional es bajo.

Ingrediente 2: Denoising posterior. La posterior sobre (μ, σ) centra y escala Q_{emp} . Sin Gibbs: AAD = 0.42 pp (Sim. Histórica pura). Con Gibbs: AAD = 0.20 pp. Los 0.22 pp de diferencia provienen de la estimación bayesiana de localización y escala, **no** del suavizado del estado latente. Es importante distinguir:

1. **Filtrado** $P(\tau_t^* \mid Y_{1:t})$: no aplicamos.
2. **Suavizado** $P(\tau_t^* \mid Y_{1:T})$: Kalman da 16 pp (asunción gaussiana destruye bimodalidad).
3. **Estimación de parámetros** $P(\mu, \sigma \mid Y_{1:T})$: esto es lo que hace el Gibbs, reduciendo AAD de 0.42 a 0.20 pp.

No-ingrediente: p_{stay} . El punto de masa es andamiaje computacional que permite que el Gibbs funcione (transición singular conjugada con emisión gaussiana), pero su valor es irrelevante para la predicción.

6 Conclusión

1. La distribución empírica Q supera a la paramétrica GIG (0.2 vs. 0.8 pp) porque captura la forma real de la marginal sin imponer asunciones funcionales.

2. El Gibbs sampler mejora la estimación por denoising bayesiano, no por suavizado del estado latente. Sin Gibbs, p_{stay} es destructivo (50 pp); con Gibbs, es irrelevante (AAD plana de 0.41 a 0.54 pp).

3. En simulación, Gibbs-a tiene el mejor desempeño global ($E_Q = 0.22$ a $k = 20$, $E_\alpha = 0.47$). Gibbs-b sufre de sesgo en α que degrada E_Q .

4. El modelo SF-Harris se reduce a: muestrear de Q_{emp} con parámetros $(\hat{\mu}, \hat{\sigma})$ estimados por Gibbs. La cadena de Harris es decorativa: está en la formulación pero no contribuye a la predicción.

References

1

- [1] Michelle Anzarut. *Stochastic Volatility Modeling with Harris Recurrent Processes*. PhD thesis, Universidad [Nombre], 2024. Tesis de doctorado.