

El Modelo SF-Harris: Replicación, Análisis Crítico y Reducción al Modelo Esencial

[Nombre del Autor]

Universidad [Nombre]

Departamento de [Departamento]

[Fecha]

Resumen

Este trabajo replica y extiende el modelo de volatilidad estocástica SF-Harris propuesto por Anzarut (2024). Replicamos la Tabla 3 de la tesis original, logrando una desviación absoluta promedio (AAD) de 0.3 pp con barras de dólar, superando los 0.8 pp reportados originalmente. A través de once pruebas experimentales, demostramos que la cadena de Harris es **decorativa**: no aporta poder predictivo más allá del que ya proporciona la distribución empírica de los datos de entrenamiento. Identificamos dos ingredientes esenciales: (1) muestreo empírico de Q y (2) estimación bayesiana de parámetros (μ, σ) para centrar y escalar la distribución predictiva. El parámetro p_{stay} , que la literatura señala como crucial, resulta no informativo: su variación de 0,0 a 0,95 dentro del muestreador de Gibbs produce AAD entre 0,41 y 0,54 pp (esencialmente plano). Discutimos aplicaciones financieras en volatilidad de volatilidad, swaps de varianza y opciones sobre VIX.

Índice general

1. Introducción	2
2. Marco Teórico	4
3. El Modelo SF-Harris	6
4. La Cadena de Harris es Decorativa	8
5. El Modelo Esencial	12
6. Aplicaciones Financieras	15
7. Conclusiones	18
A. Estadísticas detalladas	21

Capítulo 1

Introducción

1.1. Motivación

La volatilidad estocástica es un componente central de los modelos financieros modernos. Desde la opción de Black-Scholes hasta los modelos Heston y GARCH, la volatilidad se modela como un proceso latente que evoluciona en el tiempo. Sin embargo, la *predicción de cobertura* —qué tan bien un modelo calibra intervalos de probabilidad para la volatilidad futura— recibe menos atención que la predicción puntual.

El modelo SF-Harris (volatilidad estocástica con recurrencia de Harris) propuesto por Anzarut [Anzarut, 2024] combina tres ingredientes: (1) una cadena de Markov con punto de masa en el estado anterior (“estancia”) y saltos desde una distribución invariante Q , (2) un muestreador de Gibbs para estimar parámetros, y (3) una distribución GIG paramétrica para Q . El modelo reporta una AAD de 0.8 pp en la Tabla 3 de la tesis, superando a GARCH(1,1) con 3.4 pp.

1.2. Pregunta de investigación

Este trabajo se plantea la siguiente pregunta:

¿Son necesarios los tres ingredientes del modelo SF-Harris para lograr una buena cobertura predictiva, o existe un modelo más simple con rendimiento comparable?

Específicamente, investigamos:

- (I) ¿Es necesaria la cadena de Harris, o basta con muestreo iid de la distribución empírica?
- (II) ¿Es necesaria la distribución GIG paramétrica, o la empírica funciona igual de bien?
- (III) ¿El parámetro p_{stay} aporta información predictiva, o es simplemente “andamiaje computacional”?

1.3. Objetivos

1. Replicar la Tabla 3 de Anzarut [Anzarut, 2024] con datos intradiarios de IBM.
2. Evaluar cada componente del modelo SF-Harris mediante pruebas de ablación.
3. Identificar el modelo mínimo que reproduce el rendimiento del SF-Harris.
4. Caracterizar las aplicaciones financieras del modelo esencial.

1.4. Estructura de la tesis

El Capítulo 2 presenta el marco teórico. El Capítulo 3 describe el modelo SF-Harris y la replicación de la Tabla 3. El Capítulo 4 presenta once pruebas experimentales que demuestran que la cadena de Harris es decorativa. El Capítulo 5 identifica los dos ingredientes esenciales. El Capítulo 6 discute aplicaciones financieras. El Capítulo 7 concluye.

Capítulo 2

Marco Teórico

2.1. Kernels de Markov y modelos de espacio de estados

Un **kernel de Markov** $K : \mathcal{X} \times \mathcal{B}(\mathcal{X}) \rightarrow [0, 1]$ es la probabilidad condicional $K(x, A) = \mathbb{P}(X_t \in A \mid X_{t-1} = x)$. Generaliza las matrices de transición a espacios de estado continuos [Chopin and Papaspiliopoulos, 2020].

Un **modelo de espacio de estados** (SSM) apila dos kernels:

$$X_t \sim f(\cdot \mid X_{t-1}) \quad (\text{transición de estado}) \quad (2.1)$$

$$Y_t \sim g(\cdot \mid X_t) \quad (\text{emisión observacional}) \quad (2.2)$$

Las observaciones $\{Y_t\}$ **no** son Markov — heredan dependencia a través del estado latente. Filtrar consiste en computar $P(X_t \mid Y_{1:t})$ integrando sobre toda la trayectoria.

2.2. Filtrado y suavizado

El **filtrado** computa $P(X_t \mid Y_{1:t})$ usando solo datos hasta t . El **suavizado** computa $P(X_t \mid Y_{1:T})$ usando toda la serie. Para modelos lineales gaussianos, el **filtro de Kalman** da la solución exacta:

$$\hat{x}_{t|t-1} = A\hat{x}_{t-1}, \quad P_{t|t-1} = AP_{t-1}A^\top + Q \quad (\text{predicción}) \quad (2.3)$$

$$\hat{x}_t = \hat{x}_{t|t-1} + K_t(y_t - H\hat{x}_{t|t-1}) \quad (\text{actualización}) \quad (2.4)$$

donde K_t es la ganancia de Kalman.

Para modelos no gaussianos (como SF-Harris), el filtro de Kalman no aplica. La **formalización de Feynman-Kac** [Chopin and Papaspiliopoulos, 2020] proporciona el marco general: el filtrado es una secuencia de integrales $\int K(x_{t-1}, x_t) \cdot g(y_t \mid x_t) \cdot w(x_{t-1}) dx_{t-1}$, y los filtros de partículas las aproximan por muestreo de importancia secuencial.

2.3. La cadena de Harris

Definición 1 (Cadena de Harris). *Una cadena de Markov $\{X_t\}$ en $(\mathcal{X}, \mathcal{B})$ es **Harris-recurrente** si existe un conjunto pequeño C y una medida no trivial ψ tales que $\mathbb{P}(\tau_C < \infty \mid$*

$X_0 = x) = 1$ para todo $x \in \mathcal{X}$.

La cadena de Harris del modelo SF-Harris tiene kernel de transición:

$$P(X_{t+1} \mid X_t) = p_{\text{stay}} \cdot \delta_{X_t} + (1 - p_{\text{stay}}) \cdot Q \quad (2.5)$$

donde $p_{\text{stay}} = e^{-\alpha}$ es la probabilidad de estancia, δ_{X_t} es la delta de Dirac en el estado actual, y Q es la distribución invariante. La distribución estacionaria es Q : el proceso converge independientemente del valor inicial.

2.4. La distribución GIG

La distribución **Generalized Inverse Gaussian** (GIG) [Barndorff-Nielsen, 1977] tiene densidad:

$$f(x \mid \lambda, \kappa, \eta) = \frac{(\kappa/\eta)^{\lambda/2}}{2K_\lambda(\sqrt{\kappa\eta})} x^{\lambda-1} \exp\left(-\frac{\kappa x + \eta/x}{2}\right), \quad x > 0 \quad (2.6)$$

donde K_λ es la función de Bessel modificada de tercer tipo. Casos especiales: $\lambda = 1$ da la distribución hiperbólica generalizada; $\kappa \rightarrow 0$ da la gamma; $\eta \rightarrow 0$ da la inversa-gamma.

En el modelo SF-Harris original, $Q = \text{GIG}(\lambda, \kappa, \eta)$. Nuestros resultados muestran que la distribución empírica supera a la GIG paramétrica (AAD 0.2 pp vs 0.8 pp).

2.5. Muestreo de Gibbs para estimación de parámetros

El muestreador de Gibbs [Chopin and Papaspiliopoulos, 2020] produce muestras de la distribución posterior conjunta $P(\alpha, \mu, \sigma \mid Y_{1:T})$ muestreando iterativamente de cada distribución condicional completa:

1. Muestrear $\alpha \mid \mu, \sigma, Y_{1:T}$ (metropolis dentro de Gibbs)
2. Muestrear $\mu \mid \alpha, \sigma, Y_{1:T}$ (conjugado gaussiano)
3. Muestrear $\sigma \mid \alpha, \mu, Y_{1:T}$ (conjugado inverso-gamma)

Después de N_{iter} iteraciones y un período de *burn-in*, obtenemos muestras $\{(\alpha^{(i)}, \mu^{(i)}, \sigma^{(i)})\}_{i=1}^N$ que caracterizan la incertidumbre paramétrica.

Observación clave: En nuestra implementación, el muestreador de Gibbs produce estimación de parámetros (localización y escala de Q), no suavizado del estado latente $\tau_{1:T}^*$. La simulación hacia adelante comienza desde la última observación ruidosa, no desde un estado suavizado.

Capítulo 3

El Modelo SF-Harris

3.1. Especificación del modelo

El modelo SF-Harris [Anzarut, 2024] es un modelo de volatilidad estocástica con recurrencia de Harris. La volatilidad latente τ_t sigue una cadena de Markov:

$$\log(\tau_t) = \begin{cases} \log(\tau_{t-1}) & \text{con probabilidad } p_{\text{stay}} = e^{-\alpha} \quad (\text{estancia}) \\ X_t \sim Q(\mu, \sigma) & \text{con probabilidad } 1 - p_{\text{stay}} \quad (\text{salto}) \end{cases} \quad (3.1)$$

con emisión observacional:

$$Y_t = \log(\text{RV}_t) = \log(\tau_t) + \varepsilon_t, \quad \varepsilon_t \sim \mathcal{N}(0, \sigma_{\text{obs}}^2) \quad (3.2)$$

donde RV_t es la varianza realizada intradiaria y $\sigma_{\text{obs}} \approx 1,04$ para datos de 15 minutos.

La distribución invariante es Q , que Anzarut parametriza como $\text{GIG}(\lambda, \kappa, \eta)$. Cuando el proceso salta, extrae un nuevo nivel de volatilidad de Q ; cuando se queda, mantiene su valor anterior.

3.2. La tesis de Anzarut

Anzarut [Anzarut, 2024] propone:

1. Umbral ε para detectar saltos: $|X_{t+1} - X_t| > \varepsilon$ indica un salto.
2. Distribución GIG paramétrica para Q , estimada por máxima verosimilitud.
3. Muestreador de Gibbs para (α, μ, σ) con priors conjugados.
4. Ajuste de periodicidad intradiaria: $f(t) = \text{RV}_{15\text{min}}(t) / \overline{\text{RV}}$.

La Tabla 3 de la tesis reporta AAD = 0.8 pp para cobertura predictiva de $\log(\text{RV}_t)$ en datos de IBM a frecuencia de 15 minutos, superando a GARCH(1,1) (3.4 pp) y modelos Heston (>50 pp).

3.3. Replicación: Resultados de la Tabla 3

Replicamos la Tabla 3 con dos variantes de agregación temporal:

Cuadro 3.1: Cobertura predictiva de $\log(RV_t)$: SF-Harris vs. benchmarks.

Modelo	Barras	$p = 0,25$	0,50	0,75	0,85	0,90	0,95	AAD
SF-Harris Gibbs ($\varepsilon = 0,1$)	Dólar	24.4 %	50.0 %	74.8 %	85.3 %	90.1 %	94.4 %	0.3
SF-Harris Gibbs ($\varepsilon = 0,1$)	15 min	25.9 %	50.8 %	74.4 %	84.7 %	90.1 %	94.7 %	0.5
Anzarut (GIG+Gibbs)	15 min	25 %	51 %	75 %	84 %	89 %	93 %	0.8
GARCH(1,1)	15 min	23.1 %	46.6 %	70.1 %	80.6 %	86.6 %	92.7 %	3.4
Sim. Histórica	15 min	25.0 %	50.1 %	75.2 %	85.0 %	90.0 %	95.1 %	0.4

Nuestro resultado de 0.3 pp con barras de dólar supera los 0.8 pp originales por un factor de $\sim 2.7\times$. La mejora se debe al uso de la distribución empírica en lugar de la GIG paramétrica y a barras de dólar que reducen la curtosis (curtosis 0.09 vs 35.5 para barras de calendario).

3.4. Barras de dólar vs. barras de calendario

Cuadro 3.2: Estadísticas de $\log(RV)$ por tipo de barra.

Estadística	15 min	Dólar
Curtosis	35.5	0.09
Asimetría	-4.8	0.03
Desv. estándar	1.04	0.78
AAD (Gibbs $\varepsilon = 0,1$)	0.5 pp	0.3 pp

Las barras de dólar [López de Prado, 2018] muestrean a volumen constante en vez de tiempo constante, lo que reduce la asimetría y curtosis de la distribución de $\log(RV)$. Esto mejora la cobertura porque la distribución empírica Q captura mejor la forma marginal cuando los datos son menos extremos.

Capítulo 4

La Cadena de Harris es Decorativa

Presentamos once pruebas experimentales que demuestran que la dinámica de la cadena de Harris —el punto de masa $p_{\text{stay}} \cdot \delta_{X_t}$ y la construcción de tiempo continuo— no aporta poder predictivo. Llamamos a esta cadena “decorativa”: está presente en la formulación matemática pero no contribuye a la cobertura predictiva.

4.1. Descomposición de cobertura

Resultado clave: SF-Harris Gibbs ($\varepsilon = 0,1$) = Sim. Histórica = $\mathcal{N}(0, \tau^*) = 2.0$ pp (cobertura de rendimientos diarios).

Los tres modelos producen AAD idéntico para rendimientos diarios, lo que indica que toda la diferencia en la cobertura de $\log(\text{RV})$ proviene de la estimación de τ^* y no de la dinámica temporal.

4.2. Calibración de ε

El umbral ε controla cuántas observaciones se clasifican como saltos. Variamos ε desde 10^{-8} hasta 10^0 (ocho órdenes de magnitud):

Cuadro 4.1: AAD vs. ε con barras de dólar y Gibbs.

ε	10^{-8}	10^{-7}	10^{-6}	10^{-5}	10^{-4}	10^{-3}	10^{-2}	10^0
AAD (dólar)	0.2	0.2	0.2	0.2	0.2	0.2	0.2	0.2
AAD (15 min)	0.3	0.3	0.3	0.5	0.5	0.5	0.5	0.5

El AAD es **plano** en ocho órdenes de magnitud. ε no calibra nada: el muestreo empírico de Q absorbe toda la variación.

4.3. Comparación de frecuencias

La cobertura de $\log(\text{RV})$ mejora al aumentar la frecuencia de muestreo:

- 15 min: AAD 0.3 pp (ruido observacional $\sigma_{\text{obs}} \approx 1,04$)
- 30 min: AAD 0.5 pp
- 1 hora: AAD 0.8 pp
- Diario: AAD 2.0+pp (σ_{obs} domina)

El rendimiento está determinado por el ruido en la medida de RV, no por p_{stay} . A mayor frecuencia, menos ruido en la estimación de τ^* , mejor cobertura.

4.4. Datos mexicanos fuera de muestra

Evaluamos ocho activos financieros mexicanos con datos diarios (no hay datos intradiarios disponibles). La Sim. Histórica supera al SF-Harris en **todos** los activos:

Cuadro 4.2: AAD diario en datos mexicanos (pp, menor es mejor).

Activo	SF-Harris	GARCH(1,1)	Hist. Sim.	Normal	Ganador
IPC	8.5	—	3.7	10.5	Hist. Sim.
Bimbo	11.7	—	3.1	12.8	Hist. Sim.
Grupo México	11.3	—	2.2	11.9	Hist. Sim.
Walmart Mex	10.4	—	1.4	10.2	Hist. Sim.
FEMSA	8.1	—	3.3	9.8	Hist. Sim.
Cemex	10.2	—	1.6	11.5	Hist. Sim.
Banorte	9.5	—	2.0	10.1	Hist. Sim.
USD/MXN	7.8	—	1.5	9.3	Hist. Sim.

Nota: GARCH(1,1) no convergió para varios activos mexicanos por colas pesadas y tamaños de muestra cortos. Datos diarios, sin intradiarios.

Las violaciones del VaR al 95 % confirman el resultado:

Cuadro 4.3: Tasas de violación del VaR 95 % en datos mexicanos (ideal: 5 %).

Activo	SF-Harris	Hist. Sim.	Normal
IPC	~7 %	~5 %	~3 %
Bimbo	~8 %	~5 %	~2 %
Grupo México	~9 %	~4 %	~3 %
Walmart Mex	~8 %	~5 %	~2 %
USD/MXN	~7 %	~5 %	~4 %

¿Por qué falla el SF-Harris en datos diarios?

1. **Estimador ruidoso:** r_t^2 a escala diaria tiene $\sigma \approx 2,27$, haciendo que la distribución de saltos del Gibbs sea demasiado ancha. Con datos intradiarios (26 observaciones/día), $\sigma \approx 1,04$, que es manejable.
2. **Baja p_{stay} :** A escala diaria, $p_{\text{stay}} \approx 0,37$ para todos los activos. El 63 % de los días se clasifican como “saltos”; la cadena de Harris pierde memoria y se reduce a muestreo iid con ruido.
3. **Colas pesadas:** Los activos mexicanos (especialmente small-caps como Bimbo, Grupo México) tienen colas más pesadas que SPY, amplificando el problema del ruido en r_t^2 .

4.5. Fallo en detección de crisis

Usamos la sorpresa predictiva del modelo como indicador de crisis. El AUC (área bajo la curva ROC) es 0.416 — **anti-predictivo**. El modelo siempre espera colas pesadas, así que nunca se sorprende por una crisis. Para comparación, el VIX tiene $\text{AUC} = 0.841$.

4.6. Harris mezclado (doble exponencial)

Añadimos una segunda exponencial a Q : $Q = w \cdot \text{Exp}(\lambda_1) + (1 - w) \cdot \text{Exp}(\lambda_2)$. El AAD mejora en **0.0 pp**. La cola pesada ya está capturada por la distribución empírica; añadir parametrización no ayuda.

4.7. Predicción estancia/salto

Si la cadena de Harris tuviera poder predictivo, podríamos predecir si el próximo paso es una estancia o un salto. El AUC de esta clasificación binaria es 0.51 — equivalente a azar. No hay señal en los datos para distinguir estancia de salto.

4.8. Modelo de volado de moneda

El modelo de volado de moneda elimina el Gibbs y usa directamente:

$$P(X_{t+1} | X_t) = p_{\text{stay}} \cdot \delta_{X_t} + (1 - p_{\text{stay}}) \cdot Q_{\text{emp}} \quad (4.1)$$

sin denoising posterior. A $p_{\text{stay}} = 0,88$ (valor del ACF), el AAD es **50.49 pp** sin ruido observacional y **11.66 pp** con ruido. Sin denoising posterior, el punto de masa es destructivo.

4.9. Barrido de p_{stay} sin Gibbs

Variamos p_{stay} de 0 a 0.99 en el modelo de volado de moneda:

Sin Gibbs, p_{stay} es **monótonamente destructivo**: a mayor p_{stay} , peor cobertura. Sin ruido observacional, concentra probabilidad en la observación actual (ruidosa), creando un pico artificial. Con ruido, el efecto se diluye pero nunca mejora sobre $p_{\text{stay}} = 0$ (Sim. Histórica).

Cuadro 4.4: AAD vs. p_{stay} sin Gibbs (volado de moneda).

p_{stay}	0.0	0.2	0.4	0.6	0.8	0.88	0.95
Sin ruido	0.42	1.75	8.12	20.18	37.90	50.49	65.39
Con ruido	18.51	18.37	17.35	15.61	13.06	11.66	10.12

4.10. Barrido de p_{stay} con Gibbs

Dentro del muestreador de Gibbs, variamos p_{stay} de 0 a 0.95:

Cuadro 4.5: AAD vs. p_{stay} con Gibbs (parámetros fijos, sin ruido obs.).

p_{stay}	0.0	0.1	0.2	0.3	0.4	0.5	0.6	0.7	0.8	0.95
AAD	0.41	0.41	0.41	0.42	0.43	0.44	0.47	0.49	0.52	0.54

El AAD es **esencialmente plano** de 0.41 a 0.54 pp. p_{stay} no es informativo dentro del Gibbs: el muestreador produce denoising de los parámetros (μ, σ) independientemente del valor de p_{stay} .

4.11. Comparación con filtro de Kalman

El filtro de Kalman (suavizado gaussiano AR(1)) da AAD = 16 pp en log(RV). La asunción gaussiana destruye la bimodalidad de la distribución predictiva: cuando el proceso salta, la distribución es bimodal (masa en el estado actual y en Q), pero el Kalman la reemplaza con una única gaussiana que cubre ambos modos con exceso de anchura.

Capítulo 5

El Modelo Esencial

Las once pruebas del Capítulo 4 convergen en tres hallazgos estructurales.

5.1. Hallazgo 1: La distribución empírica Q es casi siempre mejor

La distribución empírica Q_{emp} (resamplear de los datos de entrenamiento) produce AAD = 0.3 pp con barras de dólar, mientras que la distribución GIG paramétrica produce AAD = 0.8 pp. La ventaja es universal: la distribución empírica captura la forma exacta de la marginal (asimetría, curtosis), mientras que la GIG impone una forma paramétrica que no ajusta bien.

Solo en colas extremas ($p > 0,999$) podría una distribución paramétrica ayudar, extrapolando más allá de la muestra. Para niveles de probabilidad prácticos ($p \leq 0,95$), la empírica es superior.

5.2. Hallazgo 2: Los saltos continuos son decorativos

La construcción de tiempo continuo del SF-Harris —tiempos de espera exponenciales entre saltos— es equivalente a una cadena de Markov discreta con probabilidad de estancia $p_{\text{stay}} = e^{-\alpha}$. No hay diferencia entre:

- “El proceso espera un tiempo exponencial con parámetro α y luego salta a un nuevo nivel de Q .” (tiempo continuo)
- “En cada paso, el proceso se queda con probabilidad p_{stay} o salta con probabilidad $1 - p_{\text{stay}}$.” (discreto)

La cobertura predictiva es idéntica porque solo importa la probabilidad de estancia por intervalo de observación, no la estructura de tiempo continuo.

5.3. Hallazgo 3: p_{stay} no es informativo

Dentro del muestreador de Gibbs, el barrido de p_{stay} de 0.0 a 0.95 produce AAD entre 0.41 y 0.54 pp — esencialmente plano. El punto de masa es **andamiaje computacional**:

permite que el Gibbs funcione (proporciona una transición singular que conjugada con la emisión gaussiana), pero su valor es irrelevante para la predicción.

¿**Por qué?** Sin denoising posterior, el punto de masa concentra probabilidad en la observación ruidosa actual (con $\sigma_{\text{obs}} \approx 1,04$ para datos de 15 minutos), creando un pico artificial en la distribución predictiva. Con denoising posterior, el punto de masa se coloca en la media posterior (que promedia el ruido), haciéndolo inofensivo — pero también innecesario, ya que cualquier p_{stay} funciona igual.

5.4. Los dos ingredientes esenciales

El modelo SF-Harris se reduce a:

1. **Distribución empírica Q :** Resamplear de los datos de entrenamiento captura la forma exacta de la marginal (asimetría, curtosis). La distribución GIG da 0.8 pp; la gaussiana da 26 pp+.
2. **Denoising posterior Gibbs:** La posterior sobre (μ, σ) promedia el ruido observacional. Sin este paso, el punto de masa es destructivo (50 pp a $p_{\text{stay}} = 0,88$).

La “receta mínima” es:

1. Ajustar (μ, σ) por Gibbs o máxima verosimilitud usando los datos de entrenamiento centrados.
2. Para cada simulación, muestrear iid de $\{x_i\} + \hat{\mu}$ donde $\{x_i\}$ son los datos centrados y $\hat{\mu}$ es la media posterior.
3. Añadir ruido observacional $\mathcal{N}(0, \hat{\sigma})$.

Esto produce 0.2–0.3 pp de AAD sin cadena de Harris.

5.5. ¿Por qué falla el filtro de Kalman?

El filtro de Kalman asume que la distribución predictiva es gaussiana. Cuando el proceso salta, la distribución real es **bimodal**: una masa en el estado actual y otra en Q . El Kalman promedia los dos modos en una única gaussiana ancha, cubriendo ambos modos con exceso de anchura (AAD = 16 pp).

La distribución empírica Q , por otro lado, preserva la bimodalidad naturalmente porque es no paramétrica.

5.6. ¿Por qué fallan los estimadores simples?

Los estimadores que no incluyen denoising posterior (Sim. Histórica con $p_{\text{stay}} = 0$, media muestral, mediana) producen AAD = 0.4–2.0 pp dependiendo de la frecuencia. La diferencia entre 0.4 pp (Hist. Sim.) y 0.2 pp (Gibbs) proviene de la estimación bayesiana de μ y σ , que:

- Centro: $\hat{\mu}$ desplaza la distribución al nivel correcto
- Escala: $\hat{\sigma}$ ajusta la anchura para compensar el ruido observacional

Sin este paso, la distribución empírica está desplazada por $\hat{\mu} - \mu_{\text{true}}$ y ensanchada por σ_{obs} .

5.7. Denoising posterior: filtrado vs. suavizado vs. estimación de parámetros

Es crucial distinguir tres niveles de denoising:

1. **Filtrado** $P(\tau_t^* | Y_{1:t})$: usa datos hasta t . No aplica aquí porque la simulación es hacia adelante.
2. **Suavizado** $P(\tau_t^* | Y_{1:T})$: usa toda la serie. No lo usamos porque (a) el kernel de Harris tiene singularidad de Dirac (FFBS no aplica), (b) el Kalman da 16 pp, y (c) p_{stay} es no informativo.
3. **Estimación de parámetros** $P(\mu, \sigma | Y_{1:T})$: ésto es lo que hace el Gibbs. Produce $\hat{\mu}$ y $\hat{\sigma}$ que centran y escalan la distribución empírica, reduciendo AAD de 0.4 pp a 0.2 pp.

El “denoising” que importa es la **estimación de parámetros**, no el suavizado del estado latente.

Capítulo 6

Aplicaciones Financieras

Aunque el modelo SF-Harris se reduce a sus ingredientes esenciales, la distribución empírica con estimación bayesiana tiene aplicaciones directas en finanzas.

6.1. Pricing de swaps de varianza

Un swap de varianza paga $RV_T - K_{\text{var}}$ al vencimiento, donde K_{var} es el *strike* de varianza. El strike justo es:

$$K_{\text{var}} = \mathbb{E}[RV_T] = \mathbb{E}[\tau_T^*] \quad (6.1)$$

La distribución empírica Q_{emp} estima directamente $\mathbb{E}[\tau^*]$ como la media de RV_t en la ventana de entrenamiento. La ventaja sobre modelos paramétricos es que Q_{emp} captura la asimetría y curtosis sin imponer una forma funcional.

Para pasar de la medida física $\mathbb{P}$ a la neutral al riesgo, se añade una prima de riesgo de volatilidad λ_v :

$$\mathbb{E}[RV_T] = e^{\lambda_v T} \cdot \mathbb{E}^{\mathbb{P}}[RV_T] \quad (6.2)$$

donde λ_v se calibra con opciones liquidas [Demeterfi et al., 1999].

6.2. Opciones sobre VIX

El VIX es la volatilidad implícita a 30 días extraída de opciones sobre el S&P 500. Nuestra distribución predictiva de τ^* proporciona intervalos de probabilidad calibrados para VIX_T :

$$P(VIX_T \leq v) \approx P\left(\sqrt{\frac{252}{T} \sum_{t=1}^T \tau_t^*} \leq v\right) \quad (6.3)$$

La distribución empírica captura la asimetría positiva del VIX (sin VIX negativo, cola derecha pesada) sin suponer normalidad.

6.3. Trading del skew de volatilidad

El *skew* de volatilidad es la diferencia entre volatilidad implícita de puts out-of-the-money y calls out-of-the-money. La distribución empírica Q_{emp} tiene asimetría negativa (colas izquierdas más pesadas para $\log(RV)$), lo que genera un skew natural.

La señal de trading consiste en comparar el skew implícito del mercado con el skew predicho por Q_{emp} :

- Si el skew implícito es más plano que el de Q_{emp} , vender straddles y comprar strangles.
- Si el skew implícito es más pronunciado, la operación inversa.

6.4. Estructura temporal de p_{stay}

Aunque p_{stay} no es informativo para la cobertura de $\log(RV)$, la probabilidad de estancia **varía con la frecuencia de muestreo**:

- 15 min: $p_{\text{stay}} \approx 0,88$ (estimado por ACF)
- Diario: $p_{\text{stay}} \approx 0,0$ (prácticamente iid)

Esto tiene una interpretación financiera: a frecuencia intradiaria, el precio “se queda” en niveles de volatilidad similares entre intervalos cortos. A escala diaria, los cambios son iid respecto a la distribución marginal.

Para *term structure modeling*, la curva $p_{\text{stay}}(f)$ podría calibrar la correlación entre volatilidades a diferentes horizontes, pero nuestra evidencia muestra que esta información no mejora la cobertura.

6.5. Trading de dispersión

La dispersión (*dispersion trading*) explota la diferencia entre la volatilidad implícita del índice y la volatilidad implícita de sus componentes. La distribución empírica Q_{emp} aplicada a cada componente estima la covarianza de la matriz de varianza-covarianza:

$$\widehat{\text{Cov}}(RV_i, RV_j) = \frac{1}{n} \sum_{t=1}^n (RV_{i,t} - \bar{RV}_i)(RV_{j,t} - \bar{RV}_j) \quad (6.4)$$

La covarianza empírica es consistente con nuestro enfoque: la distribución conjunta empírica captura correlaciones sin suponer normalidad multivariada.

6.6. Lo que NO funciona

Es igualmente importante señalar las aplicaciones donde el modelo no aporta valor:

1. **Predicción direccional:** El modelo predice la *distribución* de la volatilidad, no su dirección. Los rendimientos condicionales $r_t \mid \tau_t \sim N(0, \tau_t)$ tienen media cero por construcción.
2. **Detección de crisis:** La sorpresa predictiva tiene $AUC = 0.416$ (anti-predictivo). El modelo siempre espera colas pesadas, así que las crisis no son sorprendentes bajo el modelo.
3. **Predicción diaria:** A escala diaria, el ruido en $\hat{\tau}_t$ domina (AAD 2–12 pp). Se requieren datos intradiarios para que el modelo funcione.

Capítulo 7

Conclusiones

7.1. Resumen de hallazgos

Este trabajo demuestra tres hallazgos estructurales sobre el modelo SF-Harris:

1. **La distribución empírica Q supera a la paramétrica.** Resamplear de los datos de entrenamiento (AAD 0.3 pp) es mejor que ajustar una GIG (AAD 0.8 pp) o una gaussiana (AAD 26 pp+). La distribución empírica captura asimetría y curtosis sin imponer forma funcional.
2. **Los saltos continuos son decorativos.** La construcción de tiempo continuo es equivalente a una cadena de Markov discreta con probabilidad de estancia p_{stay} . No aporta poder predictivo.
3. **p_{stay} no es informativo.** Dentro del Gibbs, variar p_{stay} de 0 a 0.95 produce AAD entre 0.41 y 0.54 pp. El punto de masa es andamiaje computacional, no una característica predictiva.

El modelo se reduce a dos ingredientes esenciales: **distribución empírica y estimación bayesiana de parámetros**. Sin denoising posterior, el punto de masa es destructivo (50 pp a $p_{\text{stay}} = 0,88$). Con denoising, cualquier valor de p_{stay} funciona igual.

7.2. Limitaciones

1. **Datos intradiarios necesarios:** El modelo funciona a frecuencias de 15 minutos o menor. A escala diaria, el ruido en $\hat{\tau}_t$ domina (AAD 2–12 pp).
2. **Cobertura de colas extremas:** La distribución empírica no extrapola más allá de la muestra. Para $p > 0,999$, una distribución paramétrica podría ser necesaria.
3. **Estacionariedad:** El modelo asume que Q es estacionaria. En regímenes de volatilidad cambiantes, la ventana de entrenamiento puede no ser representativa.
4. **Un solo activo:** Todos los resultados son para IBM. La extensión a múltiples activos requiere estimación conjunta de la matriz de covarianza.

5. **Fuga residual train/test (declarada):** Los titulares citados —AAD 0.3 pp con barras de dólar, calendario 15 min 0.5 pp, descomposición $9,4 \rightarrow 2,0$ pp y la Tabla 3.1— se calcularon con un protocolo libre de fuga: la limpieza (umbral de saltos) y la periodicidad intradía se ajustan *solo* sobre la ventana de entrenamiento y se aplican al test. Los AADs absolutos de las pruebas auxiliares (Tests 2–10, filtro de Kalman, estimadores simples, barridos de p_{stay} y de ε) conservan aún la fuga y deben leerse como **provisionales**; no obstante, sus conclusiones *relativas* (p_{stay} decorativa: AAD esencialmente plano entre brazos; denoising de τ^* reduce el AAD) son robustas porque la fuga desplaza ambos brazos por igual.

7.3. Trabajo futuro

1. **Filtro de partículas para suavizado completo:** Un filtro de partículas que aproxime $P(\tau_t^* \mid Y_{1:T})$ podría mejorar la cobertura al denoisar el estado latente, no solo los parámetros. Sin embargo, el kernel singular del Harris hace que FFBS estándar no aplique; se requeriría una aproximación.
2. **Cambio de régimen:** Modelos con Q que cambia entre regímenes de alta y baja volatilidad podrían capturar la no-estacionariedad y mejorar la cobertura en transiciones.
3. **Pricing de opciones:** La distribución empírica bajo la medida física $\mathbb{P}$ se puede transformar a la medida neutral al riesgo usando opciones liquidas como calibración.
4. **Datos multivariados:** Extender a una canasta de activos con copulas para capturar dependencias no gaussianas.

7.4. Lo que el SF-Harris ES y NO ES

El modelo SF-Harris (reducido a sus ingredientes esenciales) **ES**:

- Un buen modelo de *cobertura* para $\log(\text{RV})$ intradiaria.
- Un método no paramétrico de predicción de distribuciones de volatilidad.
- Un marco para cuantificar incertidumbre en estimaciones de volatilidad.

El modelo SF-Harris **NO ES**:

- Un modelo de predicción direccional (señal $\alpha = 0$).
- Un detector de crisis (AUC = 0.416, anti-predictivo).
- Un modelo que funcione a escala diaria sin datos intradiarios.

Bibliografía

- Michelle Anzarut. *Stochastic Volatility Modeling with Harris Recurrent Processes*. PhD thesis, Universidad [Nombre], 2024. Tesis de doctorado.
- Ole E. Barndorff-Nielsen. Exponentially decreasing distributions for the logarithm of particle size. *Proceedings of the Royal Society of London. Series A, Mathematical and Physical Sciences*, 353(1674):401–419, 1977.
- Nicolas Chopin and Omiros Papaspiliopoulos. *An Introduction to Sequential Monte Carlo*. Springer, Cham, 2020.
- Kresimir Demeterfi, Emanuel Derman, Michael Kamal, and Joseph Zou. More than you ever wanted to know about volatility swaps. *Goldman Sachs Quantitative Strategies Research Notes*, 1999.
- Marcos López de Prado. *Advances in Financial Machine Learning*. Wiley, Hoboken, NJ, 2018.

Apéndice A

Estadísticas detalladas

A.1. Datos de IBM

Cuadro A.1: Estadísticas descriptivas de $\log(RV)$ para IBM.

Estadística	15 min	Dólar
Media	−7.02	−7.15
Desv. estándar	1.04	0.78
Asimetría	−4.8	0.03
Curtosis	35.5	0.09
Mínimo	−14.2	−9.8
Máximo	−1.3	−5.1
Observaciones	72,144	68,892
Período	2012–2022	2012–2022

A.2. Cobertura completa por nivel de probabilidad

Cuadro A.2: Cobertura predictiva de $\log(RV)$: SF-Harris Gibbs con barras de dólar.

p	0.25	0.50	0.75	0.85	0.90	0.95
Ideal	25.0 %	50.0 %	75.0 %	85.0 %	90.0 %	95.0 %
SF-Harris	25.1 %	50.2 %	75.0 %	84.9 %	90.0 %	95.1 %
Desv. (pp)	+0.1	+0.2	0.0	−0.1	0.0	+0.1

Cuadro A.3: AAD vs. ε para Gibbs con barras de dólar y 15 min.

ε	10^{-8}	10^{-7}	10^{-6}	10^{-5}	10^{-4}	10^{-3}	10^{-2}	10^0
Dólar	0.2	0.2	0.2	0.2	0.2	0.2	0.2	0.2
15 min	0.3	0.3	0.3	0.5	0.5	0.5	0.5	0.5

A.3. Barrido completo de ε

A.4. Barrido de p_{stay} : Gibbs con ruido observacional

Cuadro A.4: AAD vs. p_{stay} para tres enfoques del barrido con Gibbs.

p_{stay}	Gibbs fijo + ruido	Gibbs fijo, sin ruido	Gibbs uncertainty + ruido
0.0	18.63	0.41	18.61
0.2	18.51	0.41	18.49
0.4	18.47	0.43	18.44
0.6	18.41	0.47	18.38
0.8	18.35	0.52	18.33
0.88	18.31	0.55	18.29
0.95	18.26	0.54	18.24

Nota: Con ruido observacional, el AAD es ~ 18 pp independientemente de p_{stay} porque el ruido dominando la emisión oculta la estructura de la cadena. Sin ruido observacional, p_{stay} es plano (0.41–0.55 pp), confirmando que p_{stay} no es informativo.